

Lab 03. Optimization

Today

1. 回顾梯度下降法、牛顿法、高斯牛顿法和列文伯格-马夸特法的发展脉络。
2. 介绍作业任务。



资料存在疑惑或者不明白的可以咨询→计算机视觉导论助教（沈泽弘），2024/10/10

Today

1. 梯度下降法

数学形式

变种

2. 牛顿法

数学推导

优缺点

变种：拟牛顿法

3. 高斯牛顿法

数学推导

优缺点

4. 列文伯格-马夸特法

思想

作业

1. 梯度下降法

利用函数的一阶导数来求解最优化问题。

多元函数求导实际上是求偏导，表示每个自变量方向上的变化率。让自变量沿着损失函数梯度的反方向变化，就是梯度下降法。

如果损失函数是凸函数，则梯度下降法得到的解一定是全局最优解。否则优化的结果和初始点相关，可能会得到局部最优解。

数学形式

- 假设一阶连续可导函数 $f(x) \in \mathbb{R}$ ，定义域（参数） $x \in \mathbb{R}^n$ 。求解 $\min_{x \in \mathbb{R}^n} f(t; x)$ 。 t 是样本数据。
- Gradient Descent (GD) 通过不断迭代 x ，达到减少函数值的目的。第 $k + 1$ 次迭代值

$$x^{(k+1)} \leftarrow x^{(k)} + \lambda_k p_k$$

其中 p_k 是搜索方向，在这里取梯度的负方向。 λ_k 是搜索步长，是通过线性搜索，得到的能使得目标最小的步长。

- 当梯度不再变化时终止迭代。

变种

样本可以取“所有”、“部分”、“单个”。现在一般SGD (Stochastic-GD) 指Mini-batch GD。

2. 牛顿法

相比较GD (一阶导数)，进一步利用函数的二阶导数 (Hessian矩阵)。

数学推导

假设参数 $x \in \mathbb{R}^n$ ，无约束优化目标二阶连续可导： $x^* = \arg \min_x f(x)$

对多元函数 $f(x)$ 泰勒展开。

$$f(x) = f(x^{(k)}) + g_k^T (x - x^{(k)}) + \frac{1}{2} (x - x^{(k)})^T H(x^{(k)}) (x - x^{(k)})$$



求解函数极值的常用套路：一阶、二阶泰勒展开 (近似) 后，再对等式求导。因为极值的必要条件是一阶导数为0。

对在 $x^{(k)}$ 点处的近似泰勒展开求导 (用nabla算子 ∇)：

$$\nabla f(x) = g_k + H_k(x - x^{(k)})$$

此时，这里记 $H_k = H(x^{(k)})$ 。因为Hessian矩阵内均是数值，所以求解此近似条件下的下一个 x 点：

$$\begin{aligned} g_k + H_k(x^{(k+1)} - x^{(k)}) &= 0 \\ x^{(k+1)} &= x^{(k)} - H_k^{-1} g_k \end{aligned}$$

优缺点

缺点：计算海森矩阵计算量大 (二阶导数矩阵)，不一定可逆。

变种：拟牛顿法

用一个矩阵代替海森矩阵的逆。经典的包括DFP(Davidon-Fletcher-Powell)、BFGS(Broyden-Fletcher-Goldfarb-Shanno)、Broyden等算法。

3. 高斯牛顿法

考虑牛顿法的特殊情况：目标函数是误差的二次函数。

数学推导

在 x_0 展开误差函数 $\frac{1}{2}\|f(x)\|^2$

$$\begin{aligned}\frac{1}{2}\|f(x)\|^2 &= \frac{1}{2}(f(x_0) + J(x_0)^T(x - x_0))^2 \\ &= \frac{1}{2}(f^2(x_0) + 2f(x_0)J(x_0)^T(x - x_0) + (x - x_0)^T J(x_0)J(x_0)^T(x - x_0))\end{aligned}$$

▼ Jacobian定义

具体来说，Jacobian 矩阵是向量值函数的所有一阶偏数组成的矩阵。假设有一个从 \mathbb{R}^n 到 \mathbb{R}^m 的向量值函数 $\mathbf{f}(\mathbf{x}) = (f_1(\mathbf{x}), f_2(\mathbf{x}), \dots, f_m(\mathbf{x}))$ ，其中 $\mathbf{x} = (x_1, x_2, \dots, x_n)$ 是输入变量的向量，那么 Jacobian 矩阵 $J(\mathbf{x})$ 的定义为：

■

它是一个 $m \times n$ 的矩阵，表示的是向量函数在不同变量上的一阶偏导数。

- 如果 $m = 1$ （即标量值函数），那么 Jacobian 矩阵退化为梯度向量。
- 如果 $n = 1$ （即标量输入），那么 Jacobian 矩阵变成导数的列向量。

套路：求导为0得到

$$x_1 = x_0 - \frac{J^T f_0}{JJ^T}$$

类比牛顿法，此时 $H = JJ^T$ ， $g = J^T f$

优缺点

- 通过求偏导 J （一阶导数），避免了求海森矩阵（二阶导数），大大减少了计算量。
- 海森矩阵在凸函数时半正定的（在零特征值时不可逆），在非凸函数时存在负定或者不定的现象（不一定可逆）； JJ^T 是半正定（目标函数是凸函数，在零特征值时不可逆），性质也不是特别好。因此下面引入了列文伯格-马夸特法。

4. 列文伯格-马夸特法

思想

高斯牛顿法中，计算步长时矩阵性质如果不好，容易导致锯齿形，因此引入“信赖区域”。制定一个评判指标来动态调整步长。引入阻尼量： $H \rightarrow H + \mu I$ 。

大致的思想是：当函数估计性质很好时，用高斯牛顿，i.e. 阻尼为0。当函数估计性质不好时，用最速下降，i.e. 增大阻尼因子。当然，也可以理解为，当阻尼很大的时候步长变小。

作业

- 上交完成好的Notebook导出的PDF

- 任务：提供753个数据点 (x, y, z) ，已知这些数据点表示一个椭球。使用高斯牛顿法求解椭球参数。（下图为用scipy求解的结果，详情见notebook）

